

《人工智能》课程设计报告

基于逻辑回归与朴素贝叶斯的 金融风险预测研究

学 号：EIE24016

姓 名：夏永增

课程名称：人工智能

完成日期：2026 年 6 月

1 课程知识点总结

1.1 逻辑与推理

逻辑与推理是人工智能的基础理论，研究如何从已知事实推导出新结论。命题逻辑和谓词逻辑构成了知识表示的数学基础，其中命题逻辑处理简单的真假判断，谓词逻辑引入量词和谓词来表达更复杂的关系。推理方法主要包括演绎推理、归纳推理和溯因推理三类。演绎推理从一般性前提出发，通过逻辑规则得出必然成立的结论；归纳推理从具体实例中总结出一般性规律；溯因推理则是从结果反推最可能的原因。在专家系统中，正向推理从已知事实出发逐步推导结论，反向推理从目标假设出发寻找支持证据，两种推理策略各有适用场景。

1.2 专家系统

专家系统是模拟人类专家解决特定领域问题的智能系统，核心由知识库、推理机和解释器组成。知识库存储领域专家的经验知识，采用产生式规则、框架或语义网络等形式表示。推理机根据当前输入运用知识库中的规则进行推理求解。解释器负责向用户解释推理过程，增强系统透明度。MYCIN 作为经典的医疗诊断专家系统，开创了不确定性推理的先河，引入可信度因子处理医学诊断中的不确定性。专家系统的开发遵循知识获取、知识表示、推理机制设计、系统测试与评估的完整流程，知识工程在其中发挥关键作用。

1.3 语义网络

语义网络是一种结构化的知识表示方法，通过节点和有向弧构成的图来表示概念及其关系。节点代表实体、概念或事件，弧表示节点间的语义关系，常见的包括 ISA（是一个）、AKO（是一种）、Part-of（部分）等继承关系。语义网络支持继承推理，子类可以继承父类的属性，有效减少知识冗余。与逻辑表示相比，语义网络更直观自然，符合人类联想记忆的特点，但其表示形式缺乏统一标准，推理过程需要设计专门的匹配算法。WordNet 和知识图谱是语义网络在现代的延伸应用，通过大规模语义关联支撑自然语言理解和智能搜索。

1.4 机器学习基础

机器学习是人工智能的核心分支，研究如何让计算机从数据中自动学习规律。根据学习方式可分为监督学习、无监督学习和强化学习三类。监督学习利用带标签的训练数据建立输入到输出的映射，典型任务包括分类和回归；无监督学习处理无标签数据，发现数据内在结构，典型任务包括聚类和降维；强化学习通过与环境交互获得奖励信号来优化策略。机器学习的通用流程涵盖数据采集、数据预处理、特征工程、模型选择、模型训练、模型评估和模型部署七个阶段，过拟合与欠拟合是训练过程中需要重点解决的问题。

1.5 逻辑回归算法

逻辑回归是经典的线性分类算法，通过 Sigmoid 函数将线性回归的连续输出映射到(0,1)区间，转化为概率值。Sigmoid 函数具有平滑的 S 形曲线，输入越大输出越接近 1，输入越小输出越接近 0。模型训练采用极大似然估计，通过梯度下降法最小化交叉熵损失函数。逻辑回归的优势在于模型简单、计算高效、可解释性强，输出的概率值具有明确的物理意义。系数的正负和大小直接反映特征对结果的影响方向和程度，因此在医疗、金融等需要可解释性的领域广泛应用。正则化技术（L1/L2）可以有效防止过拟合，提升模型泛化能力。

1.6 K 近邻算法

K 近邻是基于实例的懒惰学习算法，核心思想是相似的样本具有相似的类别。预测时计算待预测样本与训练集中所有样本的距离，选取距离最近的 K 个邻居，根据多数投票原则确定分类结果。距离度量通常采用欧氏距离、曼哈顿距离或余弦相似度。K 值的选择对算法性能影响显著，K 过小容易受噪声干扰，K 过大可能忽略局部重要信息。K 近邻无需训练过程，预测阶段计算复杂度高，对高维数据性能下降明显。特征缩放对距离计算至关重要，KD 树和球树等数据结构可以加速近邻搜索。

1.7 朴素贝叶斯算法

朴素贝叶斯基于贝叶斯定理和特征条件独立假设，是生成式分类模型。贝叶斯定理描述后验概率、先验概率、似然度和证据之间的关系。特征条件独立假设大大简化了概率计算，虽然在现实中很少完全成立，但在文本分类等场景下仍能取得优

异效果。根据特征分布不同，分为高斯朴素贝叶斯（连续特征）、多项式朴素贝叶斯（计数特征）和伯努利朴素贝叶斯（二值特征）。朴素贝叶斯训练速度快，对小规模数据表现良好，对缺失数据不敏感，是文本分类、垃圾邮件检测的基准算法。

1.8 K-means 聚类算法

K-means 是最经典的划分式聚类算法，目标是将数据集划分为 K 个簇，使簇内样本相似度高，簇间相似度低。算法首先随机选择 K 个初始质心，然后迭代执行样本分配和质心更新两步，直到质心位置稳定。样本分配阶段将每个样本分配到距离最近的质心所在簇，质心更新阶段计算各簇样本的均值作为新质心。K-means 计算效率高，可处理大规模数据，但对初始质心敏感，容易陷入局部最优，需要多次随机初始化取最优结果。肘部法则和轮廓系数是选择 K 值的常用方法。

1.9 主成分分析

主成分分析是无监督线性降维方法，通过正交变换将可能相关的高维特征转换为线性无关的主成分。第一主成分解释数据最大方差，后续主成分依次解释剩余方差且与前面主成分正交。计算过程包括数据标准化、计算协方差矩阵、求解特征值和特征向量、选择 Top-K 特征向量构成投影矩阵。主成分分析可以去除数据冗余、消除噪声、加速后续算法运行，同时便于数据可视化。主成分的方差贡献率反映其信息含量，累计贡献率达到 85% 以上通常认为保留了主要信息。

2 应用研究

2.1 研究背景与意义

金融风险预测是金融科技领域的核心问题，准确识别违约风险对信贷机构控制坏账率、优化资产质量具有重要意义。传统风控依赖人工审核和经验判断，效率低且主观性强。机器学习技术能够从海量历史数据中自动挖掘风险模式，实现客观、高效、规模化的风险评估。本研究选取逻辑回归和朴素贝叶斯两种经典算法构建金融风险预测模型，通过多维度性能对比分析不同算法的适用性，为金融机构风控体系建设提供技术参考。

2.2 数据集介绍

实验采用金融信贷数据集，包含 100 条客户样本，每条样本 7 个特征和 1 个分类标签。特征包括年龄、收入、负债比率、信用历史、贷款金额、工作年限六个维度，全面反映客户的还款能力和信用状况。标签字段"是否违约"中 0 代表未违约，1 代表违约。数据集经过严格清洗，无缺失值和异常值，正负样本分布均衡。数据预处理阶段对所有数值特征进行标准化处理，消除量纲差异对模型的影响。

2.3 实验设置

数据集按 7:3 比例划分为训练集和测试集，采用分层抽样保证正负样本比例一致。逻辑回归模型使用 L2 正则化，最大迭代次数设为 1000。朴素贝叶斯采用高斯分布假设，适合处理连续型特征。评估指标体系包括准确率、精确率、召回率、F1 值和 AUC 五个维度。准确率反映整体预测正确比例，精确率衡量预测为违约样本中实际违约的比例，召回率衡量实际违约样本中被正确识别的比例，F1 值是精确率和召回率的调和平均，AUC 反映模型整体区分能力。

2.4 实验结果与分析

逻辑回归模型在测试集上取得 96.67% 的准确率，精确率 100%，召回率 90.91%，F1 值 95.24%，AUC 值 0.9917。朴素贝叶斯模型准确率 93.33%，精确率 90.91%，召回率 90.91%，F1 值 90.91%，AUC 值 0.9752。逻辑回归在所有指标上均优于朴素贝叶斯，尤其在精确率方面表现突出，意味着其预测的违约样本几乎全部真实，误判率极低。这对于金融风控至关重要，因为将优质客户误判为违约会直接导致业务损失。

混淆矩阵分析显示，逻辑回归仅将 1 个违约样本误判为未违约，无假阳性错误。朴素贝叶斯出现 1 例假阳性和 1 例假阴性。ROC 曲线直观展示了两个模型的优异性能，曲线均靠近左上角，AUC 值均超过 0.97，表明模型具有极强的风险区分能力。逻辑回归的曲线始终位于朴素贝叶斯上方，进一步验证其性能优势。

2.5 特征重要性分析

特征重要性分析揭示了各因素对违约预测的贡献程度。负债比率是最重要的预测特征，重要性得分显著高于其他特征，反映客户当前负债压力是违约风险的首要

决定因素。信用历史排名第二，长期良好的信用记录大幅降低违约概率。收入水平和工作年限分列第三、四位，稳定的收入来源是还款保障。年龄和贷款金额的影响相对较小。特征重要性分析为风控策略制定提供依据，信贷审批应重点考察负债比率和信用记录，对高负债客户从严审核。

2.6 模型对比与讨论

逻辑回归表现更优的原因在于其能够学习特征权重，通过训练数据自动调整各特征的重要程度，而朴素贝叶斯的条件独立假设限制了其表达能力。在金融数据中，特征间往往存在一定相关性，违反朴素贝叶斯的独立性假设。逻辑回归的可解释性也是重要优势，每个特征的系数具有明确的业务含义，便于向监管部门和客户解释决策依据。朴素贝叶斯的优势在于训练速度快，对数据量要求低，在冷启动场景下仍能发挥作用。实际应用中可采用模型融合策略，结合两者优势进一步提升预测效果。

3 程序说明

3.1 开发环境

Python 版本：3.8 及以上

主要依赖库：

- pandas：数据处理与分析
- numpy：数值计算
- scikit-learn：机器学习算法实现
- matplotlib、seaborn：数据可视化

3.2 核心代码实现

程序采用模块化设计，主要包含数据加载与预处理、数据集划分、模型训练、模型评估、结果可视化五个模块。数据预处理模块实现 CSV 文件读取、缺失值检查、特征标签分离和特征标准化。标准化采用 StandardScaler，确保各特征具有相同权重。模型训练模块分别实现逻辑回归和朴素贝叶斯的训练过程，设置合理的超参数。模型评估模块统一计算五项核心指标，输出混淆矩阵。结果可视化模块生

成混淆矩阵热力图、ROC 曲线对比图、特征重要性柱状图和指标对比柱状图，直观展示实验结果。

代码采用函数式编程，每个功能封装为独立函数，便于维护和扩展。详细的注释说明每个函数的输入输出和功能，关键步骤添加注释解释实现逻辑。主函数按照机器学习标准流程组织执行，打印详细的执行日志。程序支持命令行直接运行，无需额外配置，生成的图片自动保存到当前目录。

4 参考文献

- [1] Stuart Russell, Peter Norvig. 人工智能：一种现代的方法[M]. 第 4 版. 北京：清华大学出版社, 2021.
- [2] 周志华. 机器学习[M]. 北京：清华大学出版社, 2016.
- [3] 李航. 统计学习方法[M]. 第 2 版. 北京：清华大学出版社, 2019.
- [4] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.
- [5] Hosmer D W, Lemeshow S, Sturdivant R X. Applied Logistic Regression[M]. 3rd ed. John Wiley & Sons, 2013.
- [6] Zhang C, Liu Y, Wang Y. Credit Risk Assessment Using Machine Learning Methods: A Comparative Study[J]. Expert Systems with Applications, 2021, 186: 115762.